

Especificação Técnica e Documentação de ETL

Mapeamento, Transformação e Carga de Indicadores de Mortalidade Infantil (MGDI)

Documento	Manual de Processamento de Pipeline ETL (Data Engineering)	Data de Criação	17 de Maio de 2026
Ficheiro Origem	mgdi_ms_k5p.csv	Registos Totais	648 linhas
Foco de Negócio	Indicadores de Saúde Pública (Mortalidade Infantil por UF e Ano)	Status	Pronto para Produção

1. Visão Geral do Pipeline e Arquitetura

Este documento descreve as especificações técnicas para a ingestão, transformação e armazenamento do conjunto de dados de indicadores de mortalidade infantil de base governamental. O objetivo principal deste pipeline de ETL (Extract, Transform, Load) é processar métricas anuais agregadas por Unidade Federativa (UF), gerando uma tabela de factos limpa e enriquecida, além de calcular de forma dinâmica a **Taxa de Mortalidade Infantil Estimada** por cada mil nascidos vivos.

Frequência de Execução Recomendada: Anual ou sob demanda (conforme a atualização das bases de dados do Ministério da Saúde e do MGDI).

2. Análise do Ficheiro de Origem (Extract)

O ficheiro de entrada é um arquivo estruturado em formato CSV (`comma-separated values`) codificado em UTF-8, contendo dados históricos acumulados de **2000 a 2023** (24 anos de série histórica) para as **27 Unidades Federativas** do Brasil.

Dicionário de Dados Original (Campos de Entrada)

Campo Original	Tipo Original	Valores Nulos	Descrição / Observações
Indicador	String (Texto)	0%	Código identificador da métrica. Valor estático: <code>MRT.1.01</code> (Mortalidade Infantil).
Ano	Integer	0%	Ano de referência do dado, variando de 2000 a 2023.
UF	Integer	0%	Código IBGE identificador da Unidade Federativa (ex: 11, 12, 35, etc.).
Numerador - Óbitos infantis estimados	Decimal/Float	0%	Número estimado de óbitos em menores de 1 ano de idade naquela UF e ano.
Denominador - Nascidos vivos estimados	Decimal/Float	0%	Número total estimado de nascidos vivos na referida UF e ano.
Fator	Integer	0%	Constante de multiplicação de base para a taxa. Valor estático: <code>1000</code> .

3. Regras de Negócio e Transformações (Transform)

Para garantir a qualidade, integridade e facilidade de consumo analítico nas ferramentas de Business Intelligence (BI) e Data Science, são aplicadas as seguintes etapas de transformação:

- Tipagem Estrita e Conversão de Dados:** Os campos de Numerador e Denominador são convertidos de ponto flutuante (`float`) para inteiros (`int64`), uma vez que tratam de contagens absolutas de vidas humanas (óbitos e nascimentos), eliminando casas decimais desnecessárias originadas na extração.
- Enriquecimento de Dados (Lookup da dimensão UF):** O arquivo original traz apenas o código numérico IBGE da UF. O pipeline realiza um enriquecimento (join) com a tabela de referência do IBGE para mapear o código numérico à **Sigla da UF** (ex: 35 → SP) e ao **Nome da Região Geográfica** (Sudeste, Norte, etc.).
- Cálculo do Indicador Final:** É gerada uma nova métrica de negócio denominada *Taxa_Mortalidade_Infantil*, calculada através da seguinte formulação matemática:

$$Taxa = (Numerador / Denominador) \times Fator$$

O resultado é arredondado para duas casas decimais.

- Renomeação de Colunas:** Conversão dos nomes complexos e com caracteres especiais para o padrão corporativo `snake_case`.

4. Estrutura do Modelo de Destino (Load)

Os dados transformados serão carregados em uma tabela de fatos consolidada (`fato_mortalidade_infantil`) dentro do Data Warehouse / Data Lakehouse.

Nome da Coluna (Destino)	Tipo de Dados	Chave / Restrição	Regra de Mapeamento / Origem
<code>id_indicador</code>	VARCHAR(20)	FK (Dim_Indicadores)	Direto da coluna `Indicador`.
<code>ano_referencia</code>	INT	PK / FK (Dim_Tempo)	Direto da coluna `Ano`.
<code>id_uf_ibge</code>	INT	PK / FK (Dim_Geografia)	Direto da coluna `UF`.
<code>sigla_uf</code>	CHAR(2)	Atributo Enriquecido	Mapeado via lookup do código IBGE.
<code>obitos_infantis_est</code>	INT	Métrica (Fato)	`Numerador - Obitos infantis estimados` convertido para inteiro.
<code>nascidos_vivos_est</code>	INT	Métrica (Fato)	`Denominador - Nascidos vivos estimados` convertido para inteiro.
<code>fator_multiplicador</code>	INT	Constante	Direto da coluna `Fator`.
<code>taxa_mortalidade_infantil</code>	DECIMAL(5,2)	Métrica Calculada	$(obitos_infantis_est / nascidos_vivos_est) \times 1000$

5. Script de Automação do Pipeline (Python / Pandas)

O script abaixo representa a implementação oficial e idempotente do processo de ETL descrito, utilizando a biblioteca Pandas para manipulação eficiente em memória.

```
import pandas as pd
import numpy as np

def run_etl_pipeline(input_file_path, output_file_path):
    print("[ETL] Iniciando processamento do arquivo...")

    # 1. ETAPA: EXTRACT (Extração)
    df = pd.read_csv(input_file_path)

    # Dicionário de mapeamento de Códigos IBGE para Siglas das UFs
    uf_mapping = {
        11: 'RO', 12: 'AC', 13: 'AM', 14: 'RR', 15: 'PA', 16: 'AP', 17: 'TO',
        21: 'MA', 22: 'PI', 23: 'CE', 24: 'RN', 25: 'PB', 26: 'PE', 27: 'AL',
        28: 'SE', 29: 'BA', 31: 'MG', 32: 'ES', 33: 'RJ', 35: 'SP', 41: 'PR',
        42: 'SC', 43: 'RS', 50: 'MS', 51: 'MT', 52: 'GO', 53: 'DF'
    }

    # 2. ETAPA: TRANSFORM (Transformação)
    # Renomeação de colunas para snake_case corporativo
    df.rename(columns={
        'Indicador': 'id_indicador',
        'Ano': 'ano_referencia',
        'UF': 'id_uf_ibge',
        'Numerador - Obitos infantis estimados': 'obitos_infantis_est',
        'Denominador - Nascidos vivos estimados': 'nascidos_vivos_est',
        'Fator': 'fator_multiplicador'
    }, inplace=True)

    # Garantir tipagem correta (conversão de float para int nos volumes absolutos)
    df['obitos_infantis_est'] = df['obitos_infantis_est'].astype(int)
    df['nascidos_vivos_est'] = df['nascidos_vivos_est'].astype(int)

    # Enriquecimento com as Siglas das UFs
    df['sigla_uf'] = df['id_uf_ibge'].map(uf_mapping)

    # Cálculo da Métrica de Negócio: Taxa de Mortalidade Infantil por 1.000 nascidos vivos
    df['taxa_mortalidade_infantil'] = (
        (df['obitos_infantis_est'] / df['nascidos_vivos_est']) * df['fator_multiplicador']
    ).round(2)

    # Reordenar colunas para melhor organização analítica
    cols_order = [
        'id_indicador', 'ano_referencia', 'id_uf_ibge', 'sigla_uf',
        'obitos_infantis_est', 'nascidos_vivos_est', 'fator_multiplicador',
        'taxa_mortalidade_infantil'
    ]
    df = df[cols_order]

    # 3. ETAPA: LOAD (Carga)
    df.to_csv(output_file_path, index=False, encoding='utf-8')
    print(f"[ETL] Sucesso! Processados {len(df)} registros salvos em: {output_file_path}")
    return df
```

```
# Para executar o pipeline localmente:  
# run_etl_pipeline('mgdi_ms_k5p.csv', 'fato_mortalidade_infantil.csv')
```

6. Validação de Dados e Qualidade (Data Quality)

- **Garantia de Não-Nulos:** Nenhuma coluna aceita valores nulos (`NOT NULL`). Caso surjam dados nulos em execuções futuras, a linha correspondente deve ser direcionada para uma tabela de quarentena.
- **Integridade Referencial:** O campo `id_uf_ibge` deve pertencer estritamente ao intervalo de códigos válidos das UFs brasileiras (códigos oficiais IBGE entre 11 e 53). Qualquer código fora deste padrão acionará um alerta crítico de consistência.
- **Regra de Sanidade Analítica:** O número de óbitos nunca deve ser superior ou igual ao número de nascidos vivos na mesma linha (*`obitos_infantis_est` < `nascidos_vivos_est`*).